

Sistema de Reconocimiento de Actividades Humanas y Análisis Biomecánico Mediante Visión por Computadora

William Joseph Verdesoto
Algoritmos y Programación III
Universidad ICESI
Cali, Colombia
1143878894@u.icesi.edu.co

Luis Manuel Rojas Correa
Algoritmos y Programación III
Universidad ICESI
Cali, Colombia
1110363069@u.icesi.edu.co

Juan Camilo Corrales Osvath
Algoritmos y Programación III
Universidad ICESI
Cali, Colombia
1007489003@u.icesi.edu.co

Abstract—Este proyecto desarrolla un sistema de reconocimiento de actividades humanas (HAR) en tiempo real, integrando la estimación de pose con un modelo de clasificación temporal. Se emplea el *framework* MediaPipe para la detección de *landmarks* articulares y un clasificador XGBoost entrenado sobre características geométricas normalizadas extraídas mediante una ventana deslizante. El objetivo es crear una herramienta para la evaluación funcional con aplicaciones en fisioterapia y deporte. Si bien el modelo alcanzó una alta precisión (87.15%) en un conjunto de datos de prueba estático, la evaluación de la aplicación desplegada en un entorno real reveló una precisión práctica del 69%. Este trabajo demuestra que dicha brecha de rendimiento no se debe a la escasez de datos, sino a la ambigüedad de las características de ingeniería para diferenciar entre estados posturales estáticos (e.g., sentado vs. de pie). El sistema resulta robusto para clasificar movimientos dinámicos, pero sus limitaciones en escenarios sutiles subrayan la necesidad de características más descriptivas para una generalización efectiva en el mundo real.

Index Terms—Reconocimiento de Actividades Humanas (HAR), Estimación de Pose, MediaPipe, XGBoost, Análisis Biomecánico, Aprendizaje Automático.

I. INTRODUCCIÓN

El reconocimiento de actividades humanas (HAR) es un área fundamental en la visión por computadora con aplicaciones directas en salud, deporte y tecnologías de asistencia [3]. El principal desafío no reside únicamente en construir modelos precisos, sino en asegurar su generalización y robustez en escenarios prácticos, donde la variabilidad de poses, oclusiones y condiciones de captura limitan su fiabilidad [4], [3]. La brecha entre el rendimiento en conjuntos de datos curados y la aplicación en tiempo real es una limitación crítica, especialmente en dominios sensibles como el monitoreo de pacientes o población en general¹.

El presente trabajo aborda este desafío mediante el desarrollo y la evaluación crítica de un sistema que integra dos problemas computacionales: la **clasificación temporal** (asignar una etiqueta de actividad a una secuencia de *frames*)

y la **estimación de pose humana** (regresión de coordenadas de articulaciones clave) [1]. La solución propuesta utiliza MediaPipe Pose, un *framework* eficiente para la estimación de pose en 2D y 3D sobre *hardware* convencional² [2].

El objetivo principal es doble: primero, desarrollar un sistema capaz de clasificar actividades cotidianas y extraer parámetros biomecánicos; y segundo, evaluar rigurosamente su rendimiento en una aplicación en tiempo real para identificar sus fortalezas y limitaciones prácticas. Se espera que esta integración y su posterior análisis proporcionen una evaluación funcional más completa y revelen los desafíos clave en la transición de un modelo teórico a una herramienta funcional.

II. MARCO TEÓRICO

La implementación del sistema se fundamenta en tres pilares teóricos: la estimación de pose, la extracción de características biomecánicas y el modelado predictivo.

A. Estimación de Pose y MediaPipe

La estimación de pose humana es el proceso de predecir las coordenadas espaciales de las articulaciones (*landmarks*) de una persona a partir de una imagen o video. MediaPipe Pose utiliza un enfoque de detección de *landmarks* en 33 puntos clave del cuerpo. Proporciona tanto las coordenadas 2D de la imagen como las coordenadas 3D de "mundo" (un sistema de referencia con origen en el centro de las caderas del sujeto), lo que facilita el cálculo de métricas biomecánicas que son independientes de la perspectiva de la cámara [2]. La precisión de la estimación de pose es sensible al ángulo de visión de la cámara y a la oclusión, lo que requiere un diseño experimental controlado para mitigar estos factores [4].

B. Biomecánica Articular y Extracción de Características

Para transformar las coordenadas articulares en información significativa sobre el movimiento, se requiere la extracción

¹Una demostración en video del sistema desarrollado y los resultados discutidos en este informe se puede encontrar en: Enlace al Video del Proyecto.

²Se refiere a dispositivos de consumo no especializados, como computadoras portátiles con CPU estándar o teléfonos inteligentes, sin requerir GPUs de alto rendimiento.

de características geométricas y cinemáticas que sean invariantes a la posición y escala del sujeto en el encuadre. Las características utilizadas en este trabajo, que se detallan a continuación, fueron diseñadas para cumplir con este requisito:

1) *Longitud Normalizada de Pierna*: Esta métrica es fundamental para la generalización del modelo, ya que normaliza las mediciones con respecto a las proporciones del propio cuerpo del sujeto. Al hacerlo, la característica se vuelve menos sensible a variaciones en la altura del individuo o su distancia a la cámara, permitiendo que el modelo se enfoque en el patrón de movimiento en lugar de en la escala. Se calcula como el cociente entre la distancia del centro de los tobillos al centro de las caderas, y la distancia del centro de los hombros al centro de las caderas:

$$\text{normalized leg length} = \frac{\|\text{ankle}_{\text{center}} - \text{hip}_{\text{center}}\|}{\|\text{shoulder}_{\text{center}} - \text{hip}_{\text{center}}\|} \quad (1)$$

Esta normalización es fundamental para asegurar que las características extraídas sean comparables entre diferentes sujetos y configuraciones de cámara.

2) *Vectores Unitarios de Orientación*: Los vectores de hombros y tobillos se normalizan para convertirlos en vectores unitarios, capturando únicamente la dirección. Esto es necesario para cuantificar la orientación del tronco y las extremidades sin que la magnitud del vector (que depende de la escala del sujeto en la imagen) afecte la medición. Por ejemplo, para el vector de hombros $\vec{v}_{\text{sh}} = \text{shoulder}_{\text{right}} - \text{shoulder}_{\text{left}}$, los componentes normalizados son:

$$\text{shoulder vector } x = \frac{v_{\text{sh},x}}{\|\vec{v}_{\text{sh}}\|}, \quad \text{shoulder vector } z = \frac{v_{\text{sh},z}}{\|\vec{v}_{\text{sh}}\|} \quad (2)$$

La proyección de estos vectores sobre los ejes x y z permite cuantificar la inclinación del tronco y la orientación del sujeto respecto al plano de la cámara.

3) *Ángulos Articulares*: Los ángulos de articulaciones clave (cadera y rodilla) se calculan mediante el producto punto entre los vectores que unen tres *landmarks* consecutivos. Esta es una medida biomecánica directa que cuantifica la flexión y extensión, siendo esencial para diferenciar actividades que pueden tener orientaciones corporales similares pero estados de flexión articular distintos (p. ej., estar de pie vs. sentarse). Para el ángulo de cadera (θ_{hip}), dados los puntos hombro, cadera y rodilla:

$$\theta_{\text{hip}} = \arccos \left(\frac{(\text{shoulder} - \text{hip}) \cdot (\text{knee} - \text{hip})}{\|\text{shoulder} - \text{hip}\| \cdot \|\text{knee} - \text{hip}\|} \right) \times \frac{180}{\pi} \quad (3)$$

El cálculo del ángulo articular es una métrica biomecánica directa que permite evaluar la flexión y extensión, elementos esenciales para el análisis de la calidad del movimiento.

C. Modelado Predictivo: XGBoost

Para la clasificación de actividades, se seleccionó el algoritmo **XGBoost** (*Extreme Gradient Boosting*). Este es un método de *ensemble* que utiliza el *gradient boosting*, construyendo un modelo predictivo mediante la combinación aditiva de múltiples árboles de decisión débiles. Cada nuevo árbol

se entrena para corregir los errores residuales del *ensemble* acumulado hasta ese momento.

El modelo después de t iteraciones se expresa como:

$$F_t(\mathbf{x}) = F_{t-1}(\mathbf{x}) + \eta \cdot f_t(\mathbf{x}) \quad (4)$$

donde $F_{t-1}(\mathbf{x})$ es el modelo acumulado, $f_t(\mathbf{x})$ es el nuevo árbol de decisión, y η es la tasa de aprendizaje (*learning rate*). La formulación de XGBoost incluye términos de regularización que penalizan la complejidad del modelo, lo que contribuye a evitar el sobreajuste y mejorar la capacidad de generalización.

III. METODOLOGÍA

El desarrollo del sistema se adhirió al marco metodológico **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), un estándar iterativo y flexible para proyectos de ciencia de datos [5], [6]. La aplicación de CRISP-DM estructuró el trabajo en seis fases interconectadas: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Este enfoque sistemático permitió el refinamiento continuo de las características y los hiperparámetros del modelo.

A. Diseño Experimental y Recolección de Datos

La recolección de datos se llevó a cabo bajo un diseño experimental monocular controlado, con el objetivo de minimizar las fuentes de ruido y las ambigüedades de la estimación de pose.

1) *Configuración del Entorno de Captura*: El entorno se configuró para asegurar la consistencia de los datos, mitigando factores que afectan la precisión de la estimación de pose, como la iluminación y la complejidad del fondo [4]. Se estableció un umbral mínimo de **500 lux** para la intensidad lumínica, medido con un luxómetro, con el fin de garantizar una exposición constante y reducir el ruido fotométrico. Se utilizó un fondo sólido de color neutro en un espacio despejado de **4x4 metros** para evitar que texturas complejas o movimiento en el fondo introduzcan falsos positivos en la detección de articulaciones.

2) *Configuración del Dispositivo de Grabación*: La captura de video se realizó con un dispositivo móvil (iPhone 11 Pro Max). La configuración se estandarizó para mantener la consistencia temporal y espacial de los *frames*.

3) *Metodología de Captura*: Se grabaron tres repeticiones de cada actividad (caminar hacia adelante/atrás, giros, inclinaciones) a velocidades "normal", "lenta" y "rápida" para introducir variabilidad en el conjunto de datos. La metodología incluyó la revisión inmediata de cada toma para asegurar la calidad de visibilidad, enfoque e iluminación.

B. Preprocesamiento y Modelado de Datos

El conjunto de datos consolidado consta de 16,688 observaciones. Las características utilizadas son: *normalized_leg_length*, *shoulder_vector_x*, *shoulder_vector_z*, *ankle_vector_x*, *ankle_vector_z*, *average_hip_angle*, y *average_knee_angle*.

TABLE I
PARÁMETROS DE CONFIGURACIÓN DEL SISTEMA DE CAPTURA DE VIDEO

Parámetro	Configuración	Justificación
Resolución	1080p	Proporciona detalle espacial sin archivos excesivos.
Tasa de <i>Frames</i>	30 FPS	Captura la dinámica temporal de movimientos cotidianos.
Altura de Cámara	150 cm	Minimiza la distorsión de perspectiva.
Distancia Cámara-Sujeto	4 metros	Permite capturar el cuerpo completo.
Ángulo de Cámara	Frontal (0°)	Maximiza la visibilidad de las articulaciones.
Bloqueo AE/AF	Habilitado	Mantiene constantes el brillo y el enfoque.

1) *Construcción de Ventanas Temporales*: Dado que las actividades son procesos dinámicos, no es suficiente analizar cada *frame* de forma aislada. Para capturar la información secuencial, se implementó una técnica de **ventana deslizante**. Este método consiste en segmentar la serie temporal de características en sub-secuencias superpuestas de un tamaño fijo [11], [12]. En este proyecto, se utilizó una ventana de 30 *frames* (equivalente a 1 segundo de video a 30 FPS) que se desplaza un *frame* a la vez. Por cada paso, la ventana captura los últimos 30 conjuntos de 7 características, creando un vector de 210 dimensiones que representa el estado del movimiento en ese intervalo de tiempo. A esta secuencia se le asigna la etiqueta de actividad más frecuente (moda) dentro de la ventana, y el vector resultante se convierte en la entrada para el modelo de clasificación.

2) *Normalización y Balanceo de Clases*: Se aplicó la **normalización Z-score** mediante *StandardScaler* a todas las características. Este proceso, que estandariza los datos a una media de cero y una desviación estándar de uno, asegura que todas las características contribuyan equitativamente al modelo.

Para abordar el desbalance de clases, se aplicó la técnica **SMOTE** (*Synthetic Minority Over-sampling Technique*) [10] al conjunto de entrenamiento. SMOTE genera muestras sintéticas de las clases minoritarias mediante interpolación lineal entre instancias existentes y sus vecinos más cercanos, resultando en un conjunto expandido de 25,347 muestras con distribución uniforme de clases.

3) *Configuración del Modelo de Clasificación*: Se utilizó el modelo **XGBoost** [7] configurado con los siguientes hiperparámetros: $n_estimators = 250$, $max_depth = 6$, $learning_rate = 0.05$, $subsample = 0.8$, $colsample_bytree = 0.8$, y $objective = multi : softmax$. La selección de estos parámetros se realizó mediante un proceso de ajuste (*tuning*) para optimizar el rendimiento y evitar el sobreajuste.

C. Consideraciones Éticas y Análisis de Impacto

El desarrollo de este sistema se ha llevado a cabo con un profundo respeto por los principios éticos que rigen la ingeniería de software. Se requiere una evaluación rigurosa de las implicaciones éticas y sociales.

1) *Dilemas Éticos y Principios de Ingeniería*: La principal consideración ética en este proyecto es la **privacidad de los datos de video**, que contienen datos biométricos sensibles. Para abordar este y otros dilemas, se adoptó un enfoque proactivo, fundamentado en el Código de Ética y Práctica Profesional de Ingeniería del Software de la IEEE-CS/ACM. La Tabla II detalla la relación entre las decisiones clave del proyecto y los principios éticos aplicados.

TABLE II
RELACIÓN ENTRE DECISIONES ÉTICAS Y PRINCIPIOS DE INGENIERÍA

Decisión o Situación Ética Clave	Principios del Código de Ética Aplicados	Medidas Adoptadas para un Comportamiento Ético
Recolección de datos (videos de personas) : Potencial invasión de la privacidad y uso indebido de la información personal.	Sociedad : Actuar de manera coherente con el interés social, respetando la privacidad. Cliente y Empresario : Proteger la reputación del cliente (participantes) y el empresario (universidad).	Se obtuvo consentimiento informado explícito de los participantes para el uso de sus datos con fines académicos, detallando el tratamiento de la información y sus derechos como titulares.
Tratamiento y almacenamiento de datos : Riesgo de acceso no autorizado a los videos y datos biométricos.	Producto : Garantizar que el producto cumple con los más altos estándares, incluyendo la seguridad de los datos. Profesión : Avanzar en la integridad y reputación de la profesión.	Los videos fueron almacenados en un repositorio seguro con acceso restringido. Se ha garantizado que los videos originales no serán públicos.
Sesgos en el modelo de clasificación : Posibilidad de que el modelo funcione de manera menos precisa para ciertos grupos.	Juicio : Mantener la integridad e independencia en las valoraciones profesionales. Sociedad : Evitar la creación de sistemas que puedan discriminar.	Para mitigar el sesgo del modelo , se varió la velocidad de ejecución de las actividades y se aplicó SMOTE para evitar el sesgo por desbalance de clases, buscando un modelo que generalice mejor a la población.

2) Análisis de Impacto:

- **Social**: El mayor impacto positivo posible con este tipo de investigaciones es la mejora en la calidad de vida a través del monitoreo remoto de rehabilitación y la detección temprana de deterioro funcional. El riesgo social es la potencial erosión de la privacidad y la percepción de vigilancia si el sistema se implementa sin el consentimiento adecuado.

- **Económico:** La aplicación en fisioterapia remota puede reducir los costos de atención médica al disminuir la necesidad de visitas presenciales. El sistema también tiene potencial comercial en el análisis deportivo y la gamificación de ejercicios.
- **Ambiental:** El impacto ambiental es bajo, limitado al consumo energético del procesamiento de video. La elección de MediaPipe, un *framework* ligero optimizado para ejecución en dispositivos de bajo consumo, minimiza la huella de carbono en comparación con modelos de visión profunda más complejos.
- **Global:** La aplicabilidad global está condicionada por la diversidad de los datos de entrenamiento. El sistema actual, entrenado con un conjunto de datos local, podría mostrar un rendimiento reducido en poblaciones con diferentes complejidades físicas o patrones de movimiento, lo que requiere una adaptación y reentrenamiento con conjuntos de datos culturalmente diversos.

3) *Estrategias de Mitigación y Mejora:* Para mitigar los riesgos identificados y como parte de un desarrollo responsable, se proponen las siguientes estrategias:

- **Fortalecer la privacidad desde el diseño:** En futuras versiones, se podrían explorar técnicas de anonimización de video en tiempo real, como el desenfoque de rostros.
- **Auditoría de sesgos:** Implementar herramientas para auditar y cuantificar el sesgo del modelo de manera continua.
- **Transparencia y explicabilidad:** Desarrollar mecanismos para que los usuarios finales comprendan cómo funciona el sistema y qué tipo de datos se están analizando.

Esta evaluación ética y de impacto demuestra el compromiso del equipo con el desarrollo de una tecnología responsable y alineada con los valores de la profesión de ingeniería.

IV. ARQUITECTURA DEL SISTEMA

La implementación del sistema de reconocimiento de actividades se basa en una arquitectura de microservicio de visión por computadora en tiempo real, diseñada para procesar el flujo de video y generar predicciones con baja latencia.

A. Estructura y Flujo de Datos

El sistema se estructura en un servidor **Flask** (Python 3.10) que actúa como el núcleo de procesamiento y un **Cliente Web** (HTML5 + MJPEG Stream) que sirve como interfaz de usuario. El flujo de datos es secuencial y se detalla a continuación:

- 1) **Captura de Video e Interfaz (Cliente Web y 'app.py'):** El cliente web inicia una solicitud HTTP para recibir un *stream* MJPEG. El archivo 'app.py' (Controller) en el servidor Flask captura el video en tiempo real (usando OpenCV) e inicia un bucle de procesamiento de *frames*.
- 2) **Estimación de Pose (MediaPipe Pose):** Cada *frame* (BGR→RGB) se alimenta al módulo MediaPipe Pose, que detecta 33 *landmarks* corporales, proporcionando coordenadas (x, y, z) y visibilidad.

3) **Extracción de Características ('utils.py'):** Los 33 *landmarks* se transforman en 7 características geométricas por *frame* (como la longitud normalizada de pierna y los ángulos articulares), tal como se describe en la Sección II-B.

4) **Ventana Deslizante y Normalización:** Las 7 características por *frame* se almacenan en un búfer de ventana deslizante (*Sliding Window Buffer*) de 30 *frames* de longitud, resultando en un vector de 210 características. Este vector se normaliza inmediatamente utilizando el *StandardScaler* preentrenado (normalización Z-score).

5) **Clasificación (XGBoost):** El vector normalizado se introduce en el clasificador XGBoost preentrenado, que predice el ID de la clase de actividad.

6) *B. Suavizado Temporal y Predicción Final:*

La predicción de la clase se somete a un proceso de suavizado temporal (*Temporal Smoothing*) mediante un voto mayoritario (*Majority Vote*). Este post-procesamiento es fundamental para mitigar el efecto de *frames* ruidosos y evitar una tasa de predicción excesivamente alta (30 predicciones por segundo), lo que resultaría en una experiencia de usuario inestable. El proceso introduce un ligero retardo, pero estabiliza la etiqueta de actividad final. La etiqueta de actividad final se envía de vuelta al cliente web para su visualización en tiempo real.
denumerate

C. Componentes Lógicos

La arquitectura se puede descomponer en tres capas lógicas principales:

TABLE III
COMPONENTES LÓGICOS DE LA ARQUITECTURA DEL SISTEMA

Grupo	Nombre Componente	Capa	Descripción	Clase	Precisión	Exhaustividad	F1-Score	Soporte
Interfaz	Cliente Web	Presentación	Interfaz de usuarios basada en HTML5 que solicita y visualiza el <i>stream</i> MJPEG y la etiqueta de actividad final.	sitting_down	0.93	0.94	0.93	245
				sitting_still	0.95	0.96	0.95	174
				standing_still	0.79	0.85	0.82	699
				visual-standing_up	0.87	0.95	0.91	196
				turning	0.88	0.82	0.85	485
				walking_away	0.92	0.95	0.93	401
Servidor	'app.py' (Controller)	Control	Gestiona la captura de video (OpenCV), el bucle de procesamiento de <i>frames</i> y el <i>streaming</i> MJPEG hacia el cliente.	walking_towards	0.88	0.83	0.86	906
				Promedio Ponderado	0.87	0.87	0.87	3106
Procesamiento	MediaPipe Pose	Detección	Módulo de visión por computadora que extrae 33 <i>landmarks</i> 3D por <i>frame</i> .					
Procesamiento	'utils.py'	Ingeniería	Módulo responsable de calcular las 7 características geométricas a partir de los <i>landmarks</i> de MediaPipe.					
Modelado	<i>Sliding Window</i>	Preprocesamiento	Búfer de memoria que transforma la información de <i>frame</i> en una secuencia temporal de 30 <i>frames</i> (210 características).					
Modelado	<i>StandardScaler</i>	Normalización	Aplica la normalización Z-score al vector de características para asegurar la contribución equitativa al modelo.					
Modelado	XGBoost Classifier	Predicción	Algoritmo de <i>ensemble</i> que realiza la clasificación multiclase de la actividad.					
Salida	<i>Temporal Smoothing</i>	Post-procesamiento	Aplica un filtro de voto mayoritario para estabilizar la predicción de la actividad antes de la visualización.					

V. RESULTADOS

El modelo XGBoost fue evaluado sobre el conjunto de datos de prueba (3,106 muestras).

A. Evaluación del Modelo de Clasificación

El modelo alcanzó una **precisión general del 87.15%**. La Tabla IV presenta las métricas de rendimiento detalladas para cada clase.

Las clases con mejor rendimiento fueron *sitting_still* (F1: 0.95) y *sitting_down* (F1: 0.93), lo que indica que

TABLE IV
MÉTRICAS DE RENDIMIENTO DEL MODELO XGBOOST

el modelo clasifica con alta fiabilidad las actividades estáticas o de transición con movimientos amplios. La clase con el rendimiento más bajo fue *standing_still* (F1: 0.82), lo que sugiere una dificultad en la distinción de esta actividad.

VI. ANÁLISIS DE RESULTADOS

El rendimiento general del modelo, con una precisión del 87.15%, valida la estrategia de utilizar características biomecánicas derivadas de MediaPipe Pose en combinación con un clasificador de *ensemble* como XGBoost.

A. Generalización y Dependencia de Características

La decisión de utilizar características geométricas normalizadas (Ecuaciones 1, 2 y 3) fue crucial para la generalización del modelo. Al centrarse en las relaciones intrínsecas del cuerpo, el modelo se vuelve menos sensible a variaciones en la distancia del sujeto a la cámara o a la altura del individuo.

La clase *standing_still* presenta la mayor confusión, lo que se atribuye a la similitud postural con otras actividades (ej., el inicio de *walking_towards_camera*) y a la dificultad para detectar el movimiento sutil de la quietud. Esto sugiere que, a pesar de la ventana temporal, el modelo requiere una mayor ponderación de las características cinemáticas (velocidad y aceleración) para diferenciar movimientos sutiles de la quietud. La literatura especializada indica que la precisión de la estimación de pose, especialmente la profundidad (eje Z), es sensible al ángulo de visión de la cámara [4]. El diseño experimental controlado mitigó este riesgo, pero el rendimiento en escenarios no controlados podría degradarse.

B. Comparación con la Literatura

Los resultados obtenidos son comparables con los reportados en estudios que utilizan *frameworks* de estimación de pose en tareas de clasificación de actividades [8], [9]. La utilización de XGBoost, en lugar de arquitecturas de redes neuronales recurrentes (RNN) o convolucionales (CNN) más complejas, demuestra que un enfoque basado en la ingeniería de características

puede ser efectivo y computacionalmente eficiente para un conjunto de actividades bien definidas.

C. Análisis de Rendimiento de la Aplicación en Tiempo Real

Para evaluar la efectividad del sistema en un entorno práctico, se implementó la solución en una aplicación Flask y se realizaron una serie de pruebas de rutina de movimiento grabadas. El rendimiento se documentó sistemáticamente, registrando la actividad real y la predicción del modelo en intervalos de tiempo definidos. La implementación del sistema en un entorno de aplicación en tiempo real requirió la optimización del post-procesamiento de las predicciones para mejorar la experiencia del usuario. La alta tasa de *frames* (30 FPS) generaba una inestabilidad visual en la etiqueta de actividad. Para solucionar esto, se implementó un mecanismo de suavizado temporal basado en el voto mayoritario de una ventana de predicciones.

Se realizaron pruebas experimentales variando dos parámetros clave: el tamaño de la ventana de predicción y el umbral de votos necesarios para declarar una actividad. Se evaluaron ventanas de 15 *frames* (0.5 segundos), 10 *frames* (0.33 segundos) y 5 *frames* (0.16 segundos). Para la ventana de 10 *frames*, se probaron umbrales de 3, 4, 5 y 6 votos. Para la ventana de 5 *frames*, se probaron umbrales de 2, 3 y 4 votos.

El parámetro seleccionado que ofreció el mejor equilibrio entre latencia y estabilidad fue una ventana de **10 *frames*** (0.33 segundos) con un umbral de **9 votos** requeridos para la mayoría. Esta configuración asegura que la actividad clasificada se mantenga constante durante un tercio de segundo, a menos que haya un cambio de actividad muy pronunciado, lo que se traduce en una predicción estable y legible para el usuario final.

El sistema desplegado alcanzó una precisión general (*accuracy*) del **69%**, un resultado inferior al 87.15% obtenido en el conjunto de pruebas estático. Este descenso revela que la evaluación en un entorno dinámico y continuo expone vulnerabilidades críticas del modelo que no son evidentes en un conjunto de datos curado. El análisis detallado de las métricas por clase muestra un rendimiento altamente polarizado.

- a) *Fortalezas del Modelo*: El sistema demostró un rendimiento excepcional en la identificación de actividades con patrones de movimiento claros y transiciones definidas. Actividades como *sitting_down* (F1-Score: 1.00), *walking_away_from_camera* (F1-Score: 1.00) y *turning* (F1-Score: 0.95) fueron clasificadas con una fiabilidad muy alta. Esto valida que la ingeniería de características es efectiva para capturar movimientos dinámicos distintivos.
- b) *Debilidades Críticas*: El modelo exhibió un fallo total en la clasificación de dos actividades clave: *sitting_still* (F1-Score: 0.00) y *walk-*

ing_towards_camera (F1-Score: 0.00). El análisis sugiere que la causa raíz no es la falta de datos de entrenamiento, sino una **ambigüedad en las características extraídas**.

- Para los estados estáticos, las características actuales (ángulos, longitudes normalizadas) son prácticamente idénticas entre *sitting_still* y *standing_still*, haciendo que el modelo sea incapaz de diferenciarlas.
- La clase *standing_still* presentó un comportamiento anómalo: un *recall* de 1.00 junto a una *precision* de 0.21. Esto indica que el modelo la utiliza como una categoría "por defecto" o "refugio". Cuando se enfrenta a la ambigüedad de *sitting_still* o a la incertidumbre de *walking_towards_camera*, el sistema opta por la predicción genérica *standing_still*.

En conclusión, la evaluación en tiempo real demuestra que, si bien el sistema es robusto para acciones dinámicas, su aplicabilidad práctica está limitada por su incapacidad para resolver la ambigüedad en estados posturales estáticos o movimientos frontales sutiles utilizando el conjunto actual de características.

VII. CONCLUSIONES Y TRABAJO FUTURO

A. Conclusiones

Se desarrolló exitosamente un sistema de reconocimiento de actividades humanas y análisis biomecánico, integrando la estimación de pose con un modelo de clasificación *ensemble* (XGBoost). La metodología CRISP-DM proporcionó un marco estructurado que aseguró la solidez del desarrollo, desde la recolección de datos hasta el modelado.

La evaluación inicial del modelo sobre el conjunto de pruebas demostró una alta eficacia (Precisión: 87.15%), validando la estrategia de utilizar características geométricas normalizadas y ventanas temporales. Sin embargo, la evaluación subsecuente de la aplicación desplegada en tiempo real reveló una disminución del rendimiento (Precisión: 69%) y expuso debilidades críticas. Se concluye que el rendimiento del sistema en un entorno práctico está limitado no por la cantidad de datos, sino por la **ambigüedad inherente de las características de ingeniería seleccionadas**, que resultan insuficientes para diferenciar entre estados posturales estáticos (*sitting_still* vs. *standing_still*). El sistema es robusto para clasificar movimientos dinámicos claros, pero falla en escenarios donde la distinción postural es sutil.

B. Trabajo Futuro

Para mejorar la capacidad de generalización y la robustez del sistema en escenarios reales, se proponen las siguientes líneas de trabajo futuro, enfocadas en la mejora del modelo y las características:

- a) **Ingeniería de Características Avanzada:** Esta es la línea de acción prioritaria. Se debe enriquecer el conjunto de características para resolver las ambigüedades detectadas.
- Incorporar **métricas de posición vertical** (e.g., la coordenada y normalizada del centro de las caderas) para proporcionar al modelo una distinción clara entre las posturas de sentado y de pie.
 - Implementar **características de cambio de escala** (e.g., la derivada temporal del área del cuadro delimitador del esqueleto) para detectar de manera fiable el movimiento de acercamiento a la cámara (*walking_towards_camera*).
- b) **Exploración de Modelos Secuenciales:** Evaluar la aplicación de arquitecturas de redes neuronales recurrentes (RNN) o transformadores. Estos modelos están diseñados para capturar dependencias temporales complejas y podrían superar las limitaciones de la ventana deslizante fija, mejorando la distinción entre actividades cinemáticamente similares.

REFERENCES

- [1] . Bazarevsky, I. Grishchenko, K. Raveendran, et al., "BlazePose: On-device Real-time Body Pose tracking," *arXiv preprint arXiv:2006.10204*, 2020.
- [2] oogle, "MediaPipe Pose Landmark Detection Guide," [Online]. Available: https://ai.google.dev/edge/mediapipe/solutions/vision/pose_landmarker. [Accessed: Jan. 13, 2025].
- [3] . W. Kim et al., "Human Pose Estimation Using MediaPipe Pose and Optimization Method Based on a Humanoid Model," *Applied Sciences*, vol. 13, no. 4, p. 2700, 2023.
- [4] . Dill et al., "Accuracy Evaluation of 3D Pose Reconstruction Algorithms Through Stereo Camera Information Fusion for Physical Exercises with MediaPipe Pose," *Sensors*, vol. 24, no. 23, p. 7772, 2024.
- [5] . Wirth and J. Hipp, "CRISP-DM: Towards a Standard Process Model for Data Mining," *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, pp. 29-39, 2000.
- [6] . Tripathi et al., "Ensuring the Robustness and Reliability of Data-Driven Knowledge Discovery Models in Production and Manufacturing," *Frontiers in Artificial Intelligence*, vol. 4, 2021.
- [7] . Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785-794, 2016.
- [8] . Zhang, X. Zhao, and Z. Li, "A Comprehensive Study of Smartphone-Based Indoor Activity Recognition via XGBoost," *IEEE Access*, vol. 7, pp. 63706-63720, 2019.
- [9] . F. N. Bukht and A. Jalal, "A Robust Model of Human Activity Recognition Using Independent Component Analysis and XGBoost," *2024 5th International Conference on Computing, Mathematics and Engineering Technologies (iCoMET)*, pp. 1-6, 2024.
- [10] . V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321-357, 2002.
- [11] . Banos et al., "Window Size Impact in Human Activity Recognition," *Sensors*, vol. 14, no. 4, pp. 6474-6499, 2014.
- [12] . Dehghani et al., "A Quantitative Comparison of Overlapping and Non-Overlapping Sliding Windows for Human Activity Recognition Using Inertial Sensors," *Sensors*, vol. 19, no. 22, p. 5026, 2019.
- [13] . Jaén-Vargas et al., "Effects of Sliding Window Variation in the Performance of Acceleration-Based Human Activity Recognition Using Deep Learning Models," *PeerJ Computer Science*, vol. 8, p. e1052, 2022.